

Predicción de Precios de Renta de Viviendas en India Mediante Técnicas de Machine Learning (2026)

S. Morales-Giraldo, L. Toro-López
Dpto. of System Engineering and Computer Science
Universidad De Antioquia
Colombia

santiago.morales4@udea.edu.co, leandro.toro@udea.edu.co

Abstract—En este trabajo se aborda el problema de predicción de precios de renta de viviendas mediante técnicas de Machine Learning. Se realiza un análisis exploratorio de datos para comprender la estructura del conjunto de datos y se aplican métodos de preprocesamiento para su adecuación. Posteriormente, se entrenan y evalúan diferentes modelos de regresión con el objetivo de estimar el precio de renta a partir de características del inmueble. Los resultados obtenidos permiten comparar el desempeño de los modelos y evidencian la efectividad de los enfoques basados en aprendizaje supervisado para este tipo de problemas.

Index Terms—Machine Learning, regresión, predicción de precios, análisis exploratorio de datos, viviendas.

I. DESCRIPCIÓN DEL PROBLEMA

EL acceso a la vivienda es un aspecto fundamental en cualquier sociedad, y en países como India, donde existe una gran diversidad en el mercado inmobiliario, la estimación de precios de renta puede resultar compleja. Factores como la ciudad, la localidad, el tamaño del inmueble y sus características influyen significativamente en el valor del alquiler.

Los métodos tradicionales de estimación suelen basarse en criterios subjetivos o experiencia previa, lo cual puede generar inconsistencias. En este sentido, el Machine Learning ofrece una alternativa basada en datos que permite modelar la relación entre las características de una propiedad y su precio de renta.

El conjunto de datos utilizado fue obtenido de Kaggle [1] y contiene aproximadamente 4700 registros de propiedades disponibles para arriendo en distintas ciudades de India. Cada registro representa una propiedad e incluye múltiples variables descriptivas.

Las principales variables del dataset son:

- BHK: número de habitaciones (Bedroom, Hall, Kitchen)

- Rent: precio de renta (variable objetivo)
- Size: tamaño del inmueble en pies cuadrados
- Floor: piso en el que se encuentra la propiedad y total de pisos
- Area Type: tipo de área (Super Area, Carpet Area, Build Area)
- Area Locality: localidad específica
- City: ciudad
- Furnishing Status: estado de amueblado
- Tenant Preferred: tipo de inquilino preferido
- Bathroom: número de baños
- Point of Contact: tipo de contacto (propietario o agente)

Durante el análisis exploratorio de datos (EDA), se observó que el conjunto de datos no presenta valores faltantes, lo que evita la necesidad de aplicar técnicas de imputación. Sin embargo, se identificó que la variable “Floor” contiene información compuesta (por ejemplo, “1 out of 3”), por lo que fue necesario transformarla en variables numéricas independientes para facilitar su uso en los modelos.

Adicionalmente, se observó que variables como Size y BHK presentan una relación directa con el precio de renta, lo cual es consistente con la lógica del dominio. También se identificó que el precio varía significativamente entre ciudades, evidenciando la importancia de la ubicación como variable predictiva.

Las variables categóricas fueron transformadas mediante técnicas de codificación. En particular, se empleó One-Hot Encoding para variables nominales sin orden inherente (como City o Area Type), con el fin de evitar introducir relaciones artificiales entre categorías. Para variables con menor cardinalidad o donde la dimensionalidad debía controlarse, se consideró el uso de Label Encoding.

El equipo de trabajo definió como paradigma de aprendizaje principal el aprendizaje supervisado, específicamente enfocado en problemas de regresión. Esto se evidencia en el uso de múltiples modelos que requieren datos etiquetados (variables de entrada X y una variable objetivo y), tales como: Regresión Lineal, Árboles de Decisión, K-Nearest Neighbors

(KNN), Support Vector Regression (SVR,) XGBoost, Redes Neuronales (MLP). Todos estos modelos son característicos del aprendizaje supervisado, ya que aprenden una función que permite predecir un valor continuo a partir de ejemplos previamente conocidos.

II. ESTADO DEL ARTE

La predicción de precios de renta ha sido ampliamente abordada mediante técnicas de aprendizaje supervisado, formulándose principalmente como un problema de regresión sobre datos estructurados. En los trabajos analizados se observa un consenso en el uso de variables como tamaño, ubicación, número de habitaciones y características del inmueble para modelar el valor del alquiler.

El trabajo "House Rent Prediction Using Machine Learning" [2] emplea un enfoque de aprendizaje supervisado basado en modelos de regresión, específicamente Regresión Lineal y Random Forest Regressor. Este último destaca por su capacidad de modelar relaciones no lineales mediante la combinación de múltiples árboles de decisión, mejorando la precisión frente a enfoques lineales. De forma similar, en "Machine Learning for Rental Price Prediction: Regression Techniques and Random Forest Model" [3], se adopta Random Forest como técnica principal, resaltando su robustez frente a datos ruidosos y su capacidad de generalización.

Por otro lado, el estudio "Machine learning techniques for predicting home rental prices in India" [4] realiza una comparación entre múltiples algoritmos, incluyendo Regresión Lineal, Árboles de Decisión, Random Forest y Gradient Boosting. Los resultados muestran que Gradient Boosting presenta el mejor desempeño, lo cual evidencia la efectividad de los métodos ensemble avanzados para capturar patrones complejos en los datos.

En contraste, el trabajo "Training a Neural Network to Predict House Rents Using Artificial Intelligence and Deep Learning" [5] utiliza un enfoque de aprendizaje profundo mediante redes neuronales artificiales implementadas en Keras con TensorFlow. Este modelo secuencial emplea funciones de activación ReLU y el optimizador Adam, con el objetivo de minimizar la función de pérdida durante el entrenamiento y capturar relaciones altamente no lineales entre las variables.

En cuanto a la validación, los trabajos emplean principalmente la división del conjunto de datos en entrenamiento y prueba [2], [3], mientras que en el estudio [5] se incluye adicionalmente un conjunto de validación que permite monitorear el proceso de aprendizaje y detectar posibles problemas de sobreajuste. En el trabajo [4], la validación se basa en la comparación de métricas entre distintos modelos.

Las métricas utilizadas para evaluar el desempeño incluyen MAE, MSE, RMSE y el coeficiente de determinación R^2 , las cuales permiten cuantificar tanto la magnitud del error como la capacidad de ajuste del modelo. Estas métricas son

ampliamente aceptadas en problemas de regresión y facilitan la comparación entre diferentes enfoques.

Un aspecto relevante se presenta en "Training a Neural Network to Predict House Rents Using Artificial Intelligence and Deep Learning" [5], donde se emplean curvas de pérdida (loss curves) como herramienta fundamental para analizar el proceso de entrenamiento de la red neuronal. Estas curvas representan la evolución del valor de la función de pérdida a lo largo de las épocas, tanto para el conjunto de entrenamiento como para el de validación. En este caso, la pérdida se define mediante el Error Absoluto Medio (MAE), el cual se expresa como:

$$MAE = \frac{1}{n} \sum_{i=1} |y_i - \hat{y}_i|$$

El análisis de las curvas de pérdida permite evaluar el comportamiento del modelo durante el entrenamiento. Una disminución progresiva de la pérdida indica que el modelo está aprendiendo adecuadamente, mientras que una divergencia entre las curvas de entrenamiento y validación puede evidenciar sobreajuste. Por el contrario, si ambas curvas se estabilizan en valores altos, puede indicar subajuste. El proceso de optimización se realiza mediante el algoritmo Adam, el cual ajusta los pesos del modelo utilizando estimaciones de los gradientes para garantizar actualizaciones estables.

En términos de resultados, los trabajos coinciden en que los modelos basados en técnicas ensemble y aprendizaje profundo superan a los modelos tradicionales. En los estudios [2] y [3], Random Forest presenta mejoras significativas frente a la regresión lineal. En [4], Gradient Boosting alcanza un valor de R^2 cercano a 0.767, superando a otros modelos evaluados. Por su parte, en [5], la red neuronal logra predicciones con bajo error y sin evidencias significativas de sobreajuste.

En general, la literatura sugiere que los modelos no lineales, especialmente aquellos basados en métodos ensemble y redes neuronales, son más adecuados para la predicción de precios de renta debido a la complejidad de las relaciones entre variables en este tipo de problemas.

REFERENCES

- [1] S. Banerjee, "House Rent Prediction Dataset," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/iamsouravbanerjee/house-rent-prediction-dataset>
- [2] G. G. Pattar, D. G. Savakar, and A. Deshapande, "House Rent Prediction Using Machine Learning," IJEDR, vol. 13, no. 4, pp. 693–997, Oct. 2025.
- [3] R. Raju, A. Neyaz, A. Ahmed, and A. Singh, "Machine Learning for Rental Price Prediction: Regression Techniques and Random Forest Model," SSRN, Sep. 2023. [Online]. Available: <https://ssrn.com/abstract=4587725>. doi: 10.2139/ssrn.4587725
- [4] P. Jayadharshini, S. Santhiya, S. Keerthika, N. Abinaya, and S. Priyanka, "Machine learning techniques for predicting home rental prices in India," in Proc. 5th Int. Conf. Computing and Data Science, 2023, pp. 118–124, doi: 10.54254/2755-2721/29/20231181.
- [5] Y. Yang, H.-M. Dai, C.-H. Chao, S. Wei, and C.-F. Yang, "Training a Neural Network to Predict House Rents Using Artificial Intelligence and Deep Learning," Sensors and Materials, vol. 35, no. 10, pp. 4671–4680, 2023.